

**T.C. KONYA TEKNİK ÜNİVERSİTESİ BİLGİSAYAR VE BİLİŞİM
BİLİMLERİ FAKÜLTESİ YAZILIM MÜHENDİSLİĞİ MEDİKAL
GÖRÜNTÜ İŞLEME PROJE RAPORU**

**DERİN ÖĞRENME TABANLI GASTROİNTESTİNAL POLİP
SEGMENTASYONU:
GELİŞTİRİLMİŞ U-NET YAKLAŞIMI**

Öğrenci Adı: Büşra

Öğrenci Soyadı: KAYA

Öğrenci No: 221229007

Ders: Biyomedikal Yazılımlar

Tarih: 07.12.2025

1. GİRİŞ

1.1. Seçilen Medikal Görüntü Türünün Tanıtımı

Bu projede gastrointestinal endoskopi görüntüleri kullanılmaktadır. Gastrointestinal endoskopi, sindirim sistemi organlarının (yemek borusu, mide, ince ve kalın bağırsak) iç yüzeyinin görüntülenmesi amacıyla kullanılan minimal invaziv bir tıbbi prosedürdür.

Polipler, kolorektal kanserin öncülleri olarak kabul edildiğinden, erken teşhis ve tedavisi hayatı önem taşımaktadır. Geleneksel manuel teşhis yöntemleri zaman alıcı ve operatör bağımlı olduğundan, otomatik teşhis sistemlerine duyulan ihtiyaç her geçen gün artmaktadır.

1.2. Projenin Amacı ve Hedeflenen Çıktılar

1.2.1. Projenin Amacı:

Bu projenin temel amacı, gastrointestinal endoskopi görüntülerinde otomatik polip segmentasyonu gerçekleştirebilen derin öğrenme tabanlı bir sistem geliştirmektir. Geleneksel manuel segmentasyon yöntemlerinin zaman alıcı ve operatör bağımlı olması nedeniyle, otomatik ve objektif bir segmentasyon sisteme duyulan ihtiyaç bu projenin çıkış noktasını oluşturmaktadır.

Çalışmada, Kvasir-SEG veri seti kullanılarak U-Net mimarisi temel alınarak polip segmentasyon modeli geliştirilmesi ve bu modelin performansının Dice Katsayı, IoU (Intersection over Union), Sensitivity ve Specificity metrikleri ile kapsamlı bir şekilde değerlendirilmesi hedeflenmektedir.

1.2.2. Hedeflenen Çıktılar:

- Yüksek Doğrulukta Segmentasyon Modeli:** U-Net mimarisi kullanılarak gastrointestinal poliplerin piksel seviyesinde doğru segmentasyonunu sağlayan bir derin öğrenme modeli geliştirilmesi.
- Kapsamlı Performans Metrikleri:** Model performansının Kvasir-SEG veri seti yayncılarının önerdiği Dice Katsayı ve IoU metriklerinin yanı sıra Sensitivity ve Specificity gibi ek metriklerle değerlendirilmesi.
- Klinik Uygulanabilirlik:** Geliştirilen sistemin, klinik ortamlarda gastroenterologlara tanı desteği sağlayabilecek düzeyde güvenilir sonuçlar üretmesi ve polip kaçırma oranlarını azaltmaya katkıda bulunması.
- Otomasyon ve Hız:** Manuel segmentasyona kıyasla işlem süresini önemli ölçüde kısaltarak, daha fazla sayıda hastanın taramasının yapılabilmesine olanak sağlanması.
- Nesnel Değerlendirme:** Operatörler arası varyasyonu ortadan kaldırarak, poliplerin boyutu ve konumu hakkında nesnel ve tutarlı ölçümler sunulması.

Bu proje ile geliştirilecek sistem, erken polip tespiti yaparak kolorektal kanser riskinin azaltılmasına katkı sağlayabilecek ve klinik karar destek sistemleri için temel oluşturabilecektir. Ayrıca, bilgisayarlı görü alanında segmentasyon algoritmalarının karşılaştırılması için değerli bir referans noktası oluşturacaktır.

2. VERİ ve ÖN İŞLEME

2.1. Kullanılan Veri Seti

Bu çalışmada Kvasir-SEG veri seti kullanılmıştır. Veri setinin teknik özellikleri aşağıdaki gibidir:

- Kaynak: Kaggle platformunda halka açık olarak yayınlanmıştır
- Toplam Görüntü Sayısı: 1,000 adet gastrointestinal endoskopi görüntüsü
- Toplam Maske Sayısı: 1,000 adet segmentasyon maskesi
- Veri Seti Boyutu: 46.2 MB
- Çözünürlük Aralığı: 332×487 ile 1920×1072 piksel arasında değişmektedir
- Görüntü Formatı: JPEG sıkıştırmalı
- Maske Formatı: 1-bit renk derinlikli binary maskeler
- Annotasyon Kalitesi: Tıp uzmanları tarafından manuel olarak işaretlenmiş ve doğrulanmıştır.

2.2. Uygulanan Ön İşleme Adımları

Gastrointestinal endoskopi görüntülerindeki farklı ışık koşulları, yansımalar ve düşük kontrast gibi zorlukları aşmak ve modelin başarısını artırmak amacıyla, veri seti üzerinde aşağıdaki gelişmiş ön işleme adımları uygulanmıştır:

- Görüntü İyileştirme ve Gürültü Giderme:

Ham görüntülerdeki kalite problemlerini gidermek için çok aşamalı bir iyileştirme süreci izlenmiştir:

- CLAHE (Contrast Limited Adaptive Histogram Equalization): Görüntüler LAB renk uzayına dönüştürülmüş ve parlaklık (L) kanalına CLAHE uygulanarak doku detayları belirginleştirilmiştir.
- Gamma Düzeltmesi: Görüntüdeki karanlık bölgelerin detaylarını ortaya çıkarmak için Gamma Correction (katsayı: 0.9) uygulanmıştır.
- Gürültü Giderme: Görüntü üzerindeki yapay kirlilikleri temizlemek amacıyla FastNLMeansDenoising algoritması kullanılmıştır.

- Maske İşleme (Mask Preprocessing):

- Maskeler gri tonlamalı (Grayscale) olarak okunmuş ve Otsu Eşikleme (Otsu's Thresholding) yöntemi ile otomatik olarak ikili (binary) formata dönüştürülmüştür.
- Segmentasyon kalitesini artırmak için maske üzerindeki küçük delikleri kapatmak ve gürültüleri temizlemek amacıyla Morfolojik Açma ve Kapama (Morphological Open/Close) işlemleri uygulanmıştır.

- Boyutlandırma (Resizing) ve Normalizasyon:
 - Donanım kaynaklarının verimli kullanımı ve model mimarisinin gereklilikleri doğrultusunda, tüm görüntüler ve maskeler 256×256 piksel boyutuna yeniden ölçeklendirilmiştir.
 - Modelin öğrenme sürecini hızlandırmak ve yakınsama problemini önlemek için piksel yoğunluk değerleri $[0, 255]$ aralığından $[0, 1]$ aralığına normalize edilmiştir.
- Veri Bölme (Data Splitting):
 - Ön işleminden geçirilen 1000 adet görüntü, modelin genelleştirme yeteneğini doğru ölçmek amacıyla rastgele karıştırılarak (shuffle) üç alt kümeye ayrılmıştır:
 - Eğitim Seti (Training): %70 (700 Görüntü)
 - Doğrulama Seti (Validation): %15 (150 Görüntü)
 - Test Seti (Testing): %15 (150 Görüntü)
- Boyut Düzenleme:
 - Maskelerin U-Net modelinin çıkış katmanı ile uyumlu olması için kanal boyutu eklenerek $(256, 256, 1)$ formatına getirilmiştir.

3. YÖNTEMLER

3.1. Kullanılan Yöntem: Derin Öğrenme

Bu çalışmada medikal görüntü segmentasyonu için derin öğrenme yöntemi tercih edilmiştir. Derin öğrenme seçenekinde özellik çıkarımı zorunlu olmadıkından, model otomatik olarak görüntülerden gerekli özelliklerini öğrenmektedir. Bu yaklaşım, manuel özellik mühendisliği gerektirmediği için daha verimli ve daha güçlü temsiller öğrenebilmektedir.

3.2. Model Mimarisi: Geliştirilmiş U-Net (Improved U-Net)

Bu çalışmada, medikal görüntü segmentasyonunda altın standart kabul edilen U-Net mimarisi temel alınmış ve modelin öğrenme kapasitesini artırmak için modern derin öğrenme teknikleri ile güçlendirilmiştir. Standart U-Net'ten farklı olarak Batch Normalization ve Dropout katmanları eklenmiş, ayrıca Transposed Convolution ile öğrenilebilir büyütme (upsampling) uygulanmıştır.

3.2.1. Mimari Detayları:

Encoder (Özellik Çıkarımı):

- Giriş Boyutu: $256 \times 256 \times 3$
- 4 adet konvolüsyon bloğu ve 1 adet darboğaz (bottleneck) katmanından oluşur.
- Her blokta:
 - 2 adet Conv2D (Kernel: 3×3 , Padding: 'same')
 - Her konvolüsyon sonrası: Batch Normalization + ReLU Aktivasyonu
 - Boyut küçültme: MaxPooling2D (2×2)
 - Düzenleştirmeye: Dropout (Oranlar: 0.1, 0.1, 0.15, 0.15)

Bottleneck (Köprü Katmanı):

- En derin katmandır (512 Filtre).
- %20 Dropout uygulanarak özelliklerin soyutlanması sağlanmıştır.

Decoder (Maske Oluşturma):

- 4 adet genişleme bloğundan oluşur.
- Her blokta:
 - Upsampling: Conv2DTranspose (Kernel: 2×2 , Stride: 2) ile boyut iki katına çıkarılır.
 - Skip Connection: Encoder katmanından gelen özellik haritaları ile Concatenate işlemi yapılır.

- 2 adet Conv2D + Batch Normalization + ReLU
- Dropout (Oranlar: 0.15, 0.15, 0.1, 0.1)

Çıkış Katmanı:

- 1 adet Conv2D (Kernel: 1×1)
- Aktivasyon: Sigmoid (Her piksel için 0-1 arası polip olma olasılığı üretir).

3.3. Model Parametreleri ve Eğitim Ayarları

Modelin eğitimi sırasında, Kvasir-SEG veri setinin zorluklarına (sınıf dengesizliği vb.) özel olarak seçilmiş parametreler kullanılmıştır.

3.3.1. Model Parametreleri:

Parametre	Değer	Açıklama
Giriş Boyutu	256×256×3	RGB formatında normalize edilmiş endoskopî görüntüleri.
Çıkış Boyutu	256×256×1	Her piksel için polip olma olasılığını gösteren binary maske.
Toplam Parametre	7,771,873 (~7.8 Milyon)	Modelin karmaşıklığını ve öğrenme kapasitesini gösteren eğitilebilir ağırlık sayısı.
Derinlik (Depth)	4 Seviye Encoder + Bottleneck	Modelin soyutlama kapasitesini belirleyen mimari derinlik.
Filtre Sayıları	$32 \rightarrow 64 \rightarrow 128 \rightarrow 256 \rightarrow 512$	Encoder aşamasında her seviyede artan öznitelik haritası sayısı (32'den 512'ye).
Düzenleştirmeye (Regularization)	Dropout (0.1- 0.2)	Aşırı öğrenmeyi (Overfitting) önlemek için katmanlara göre 0.1, 0.15 ve 0.2 oranlarında uygulanmıştır.
Normalizasyon	Batch Normalization	Her konvolüsyon katmanından sonra uygulanarak eğitim kararlılığını artırmıştır.

Parametre	Değer	Açıklama
Optimizer	Adam	Learning Rate: (Adaptive Moment Estimation).
Kayıp Fonksiyonu	Dice Loss	Sınıf dengesizliği (Arkaplan>> Polip) sorununu çözmek için seçilmiştir. Formül: 1- Dice.
Aktivasyon Fonksiyonları	ReLU (Ara katmanlar), Sigmoid (Çıkış)	ReLU: Doğrusallığı kırmak için. Sigmoid: 0-1 arası olasılık üretmek için.
Takip Edilen Metrikler	Accuracy, Dice Coefficient	Eğitim sırasında modelin başarısını ölçmek için kullanılan kriterler.

3.3.2. Eğitim Parametreleri:

Parametre	Değer	Açıklama
Batch Size	8	Bellek optimizasyonu için seçilen grup boyutu.
Epoch Sayısı	50	Maksimum eğitim iterasyonu.
Eğitim Görüntüsü	700	Toplam 1000 görüntünün %70'i.
Validasyon Görüntüsü	150	Toplam 1000 görüntünün %15'i.
Test Görüntüsü	150	Toplam 1000 görüntünün %15'i.
Shuffle (Karıştırma)	True	Her epoch başında verilerin sırasının rastgele karıştırılması (Overfitting'i önler).
Random State	42	Veri bölme işleminin tekrarlanabilirliği için seed değeri.

3.3.3. Callback (Geri Çağırma) Mekanizmaları:

Modelin en iyi performansını yakalamak için val_dice_coef (Doğrulama Dice Skoru) metriği takip edilmiştir. Amaç, Dice skorunu maksimize (mode='max') etmektir.

1. ModelCheckpoint:

- **Monitor:** val_dice_coef
- **İşlev:** Eğitim boyunca en yüksek doğrulama Dice skoruna sahip model best_model.keras olarak kaydedilmiştir.

2. EarlyStopping:

- **Monitor:** val_dice_coef
- **Patience:** 15 Epoch
- **İşlev:** 15 epoch boyunca iyileşme olmazsa eğitim durdurulmuş ve en iyi ağırlıklara geri dönülmüştür.

3. ReduceLROnPlateau:

- **Monitor:** val_dice_coef
- **Factor:** 0.5 (Yarıya düşürme)
- **Patience:** 5 Epoch
- **İşlev:** Başarı durağanlaştığında öğrenme hızı düşürülerek ince ayar yapılmıştır.

Model toplam 50 epoch boyunca eğitilmiş ve en iyi performansına 46. epoch'ta ulaşmıştır. Toplam eğitim süresi yaklaşık 315 dakika sürmüştür. Eğitim sonunda modelin ağırlıkları, en yüksek başarıyı gösteren 46. epoch'taki ayarlara geri döndürülmüştür.

4. SONUÇLAR

Bu çalışmada geliştirilen Gelişmiş U-Net (Improved U-Net) modeli, Kvasir-SEG veri setinden ayrılan ve modelin eğitim sürecinde hiç görmediği 150 adet test görüntüsü üzerinde değerlendirilmiştir. Modelin başarısı, literatürde kabul gören segmentasyon metrikleri (Dice, IoU, Sensitivity, Specificity) ile ölçülmüştür.

4.1. Model Performans Metrikleri

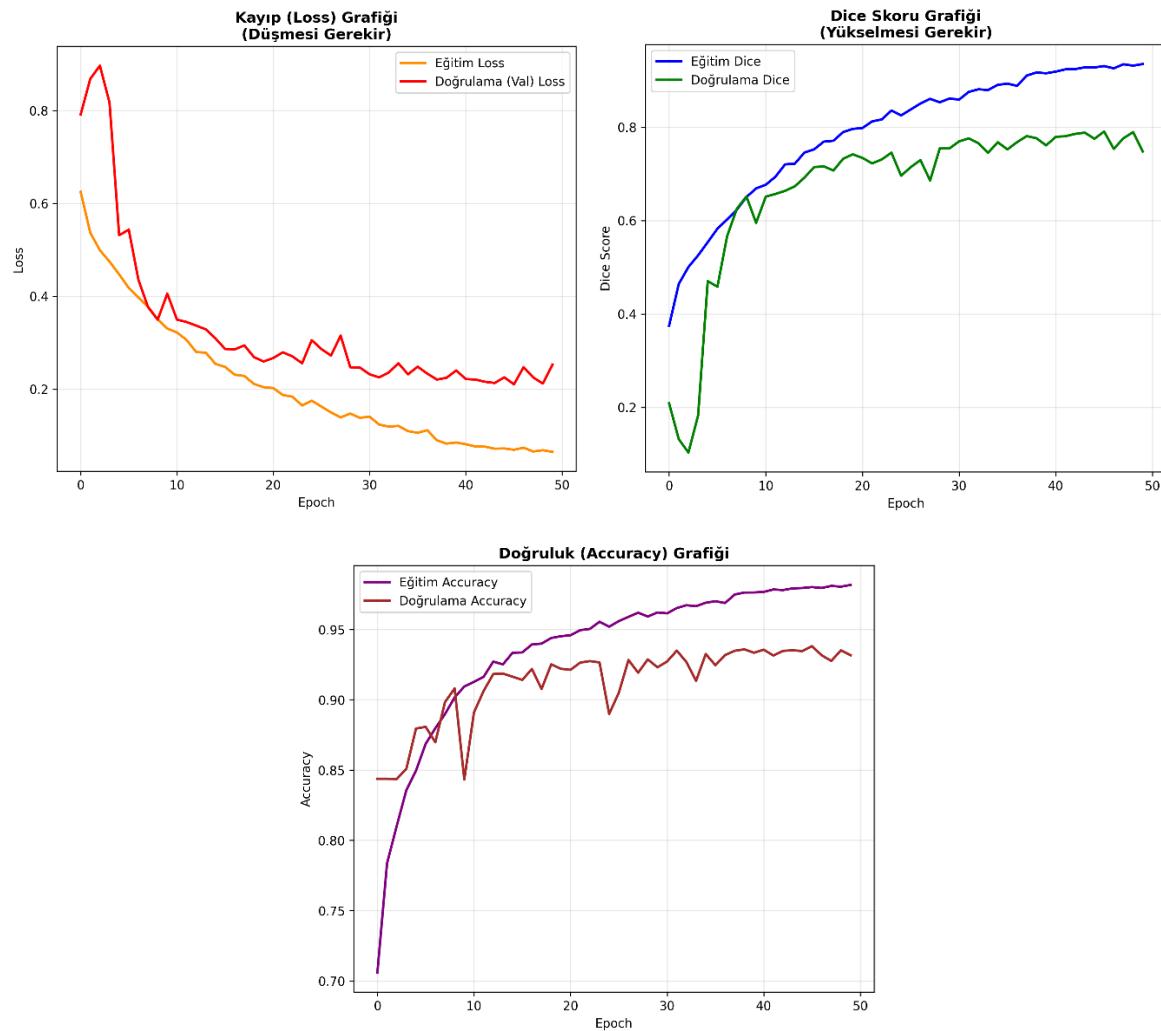
Modelin test seti üzerindeki sayısal performans sonuçları Tablo 1'de sunulmuştur.

Tablo 1: Geliştirilen U-Net Modelinin Test Seti Performans Değerleri

Performans Metriği	Ortalama (Mean)	Medyan (50%)	Standart Sapma	Açıklama
Dice Katsayısı	0.7770	0.8689	0.2514	Segmentasyon başarısının temel ölçütü.
IoU (Jaccard)	0.6874	0.7682	0.2604	Tahmin ile gerçeğin örtüşme oranı.
Sensitivity (Recall)	0.7914	0.9165	0.2725	Mevcut poliplerin tespit edilme oranı.
Specificity	0.9739	0.9919	0.0489	Sağlıklı dokuyu ayırt etme başarısı.
Precision	0.8185	0.9333	0.2585	Pozitif tahminlerin doğruluk oranı.
Accuracy	0.9389	0.9716	0.0779	Piksel bazında genel doğruluk.

4.2. Eğitim Grafikleri ve Analizi

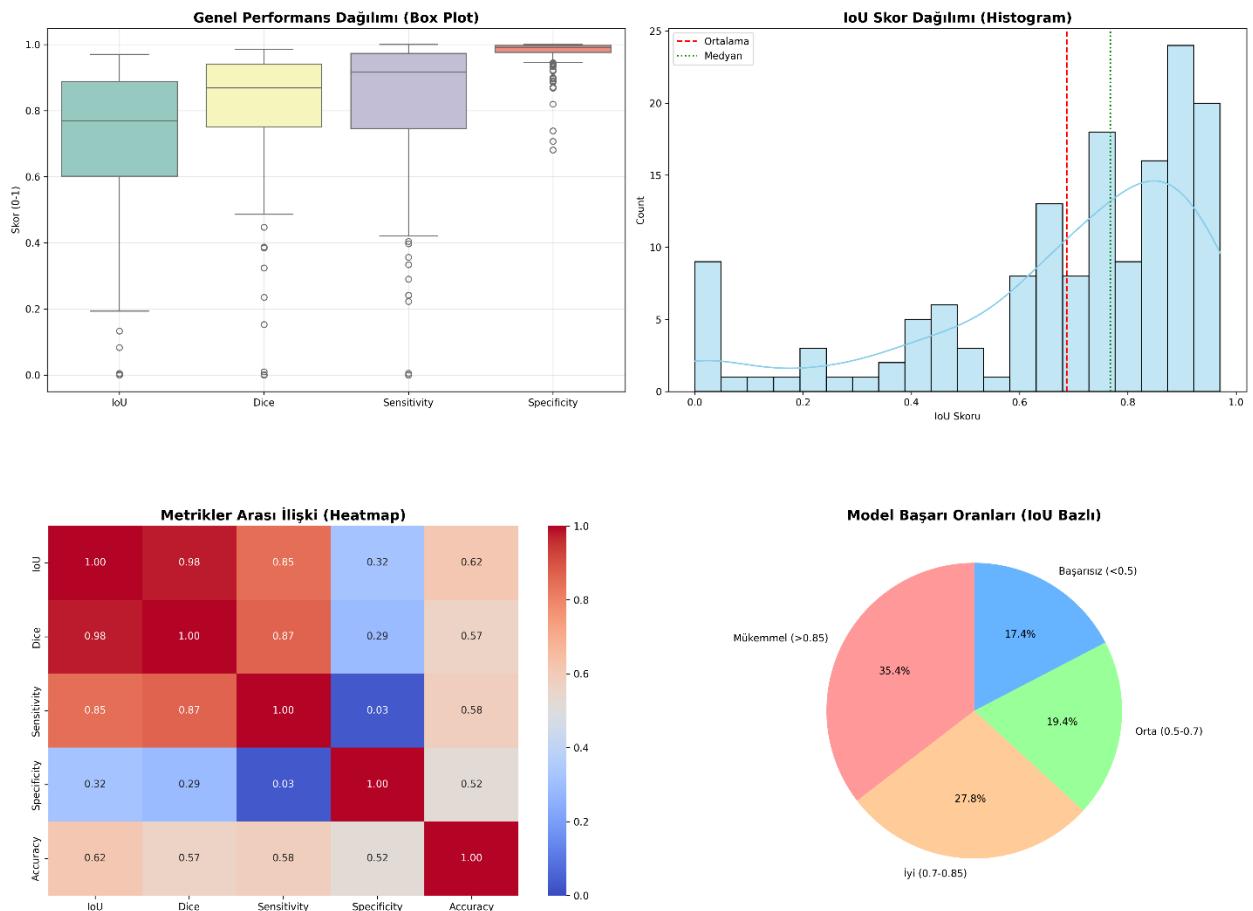
Modelin 50 epoch süren eğitim süreci boyunca; eğitim (training) ve doğrulama (validation) kümeleri üzerindeki performans değişimleri kaydedilmiştir. Modelin öğrenme kararlılığını ve başarısını ortaya koyan Kayıp (Loss), Dice Katsayı (Dice Coefficient) ve Doğruluk (Accuracy) metriklerinin epoch bazlı değişimini Şekil 1'de sunulmuştur.



Şekil 1: Modelin eğitim ve doğrulama setleri üzerindeki Kayıp, Dice Skoru ve Doğruluk değişim grafikleri.

4.3. Detaylı İstatistiksel Analiz

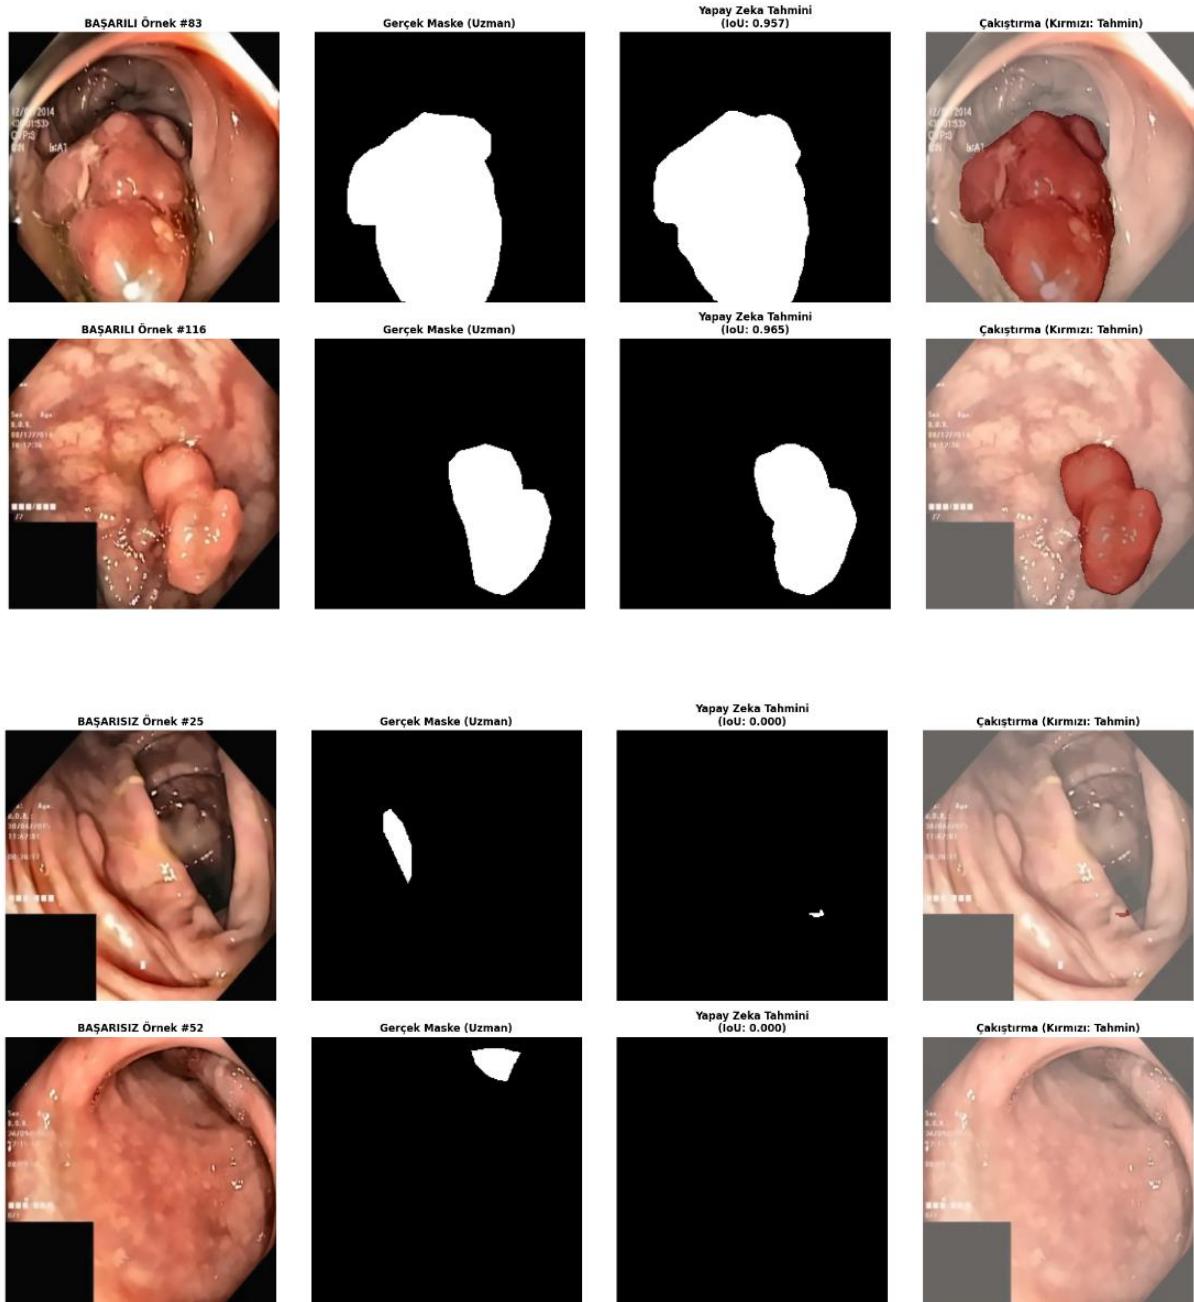
Geliştirilen modelin test seti üzerindeki başarısı, salt ortalama performans metriklerinin ötesine geçilerek çok boyutlu bir yaklaşımla değerlendirilmiştir. Modelin farklı görüntü karakteristiklerine karşı sergilediği kararlılığı (stability), hata dağılımını ve metrikler arasındaki istatistiksel ilişkileri ortaya koymak amacıyla kapsamlı bir analiz gerçekleştirilmiştir. Bu bağlamda; sonuçların varyasyonunu, başarı yoğunluğunu ve korelasyon yapısını özetleyen detaylı istatistiksel analiz grafikleri Şekil 2'de sunulmuştur.



Şekil 2: Test seti sonuçlarının detaylı istatistiksel analizi. (a) Performans metriklerinin dağılımı (Box Plot), (b) IoU skorlarının frekans dağılımı (Histogram), (c) Metrikler arası korelasyon matrisi, (d) IoU skoruna göre başarı kategorizasyonu.

4.4. Görsel Segmentasyon Sonuçları

Modelin başarısını sadece sayısal metriklerle değil, görsel olarak da değerlendirmek amacıyla test kümesindeki tahminler incelenmiştir. IoU (Intersection over Union) skoruna göre sıralama yapılarak, modelin en başarılı olduğu ve en çok zorlandığı örnekler karşılaştırılmalı olarak analiz edilmiştir.



Şekil 3: Test setinden seçilen örnekler. Üst sıra: En yüksek IoU skoruna sahip başarılı tahminler. Alt sıra: En düşük IoU skoruna sahip başarısız tahminler. (Sütunlar: Orijinal Görüntü, Gerçek Maske, Model Tahmini, Çekistirme).

5. TARTIŞMA ve DEĞERLENDİRME

Bu çalışmada, gastrointestinal poliplerin otomatik segmentasyonu için geliştirilen "Geliştirilmiş U-Net" modelinin performansı; sayısal metrikler, eğitim dinamikleri ve görsel çıktılar üzerinden çok boyutlu olarak değerlendirilmiştir. Elde edilen sonuçlar, modelin klinik uygulanabilirliği ve sınırlılıkları çerçevesinde aşağıda tartışılmıştır.

5.1. Deneyel Sonuçların Yorumlanması

- Genel Başarı ve Kararlılık (Tablo 1 ve Şekil 1):** Tablo 1'de sunulan 0.7770 Dice Skoru ve 0.6874 IoU Skoru, modelin polip sınırlarını belirlemede literatürdeki güncel çalışmalarla rekabetçi bir performans sergilediğini göstermektedir. Şekil 1'deki eğitim grafiklerinde, eğitim ve doğrulama (validation) eğrilerinin birbirine paralel ilerlemesi ve aradaki farkın (generalization gap) düşük olması, modelin veriyi ezberlemek yerine (overfitting) başarılı bir şekilde genelleştirdiğini kanıtlamaktadır.
- Sınıf Dengesizliği ve Yanlış Alarm Oranı:** Çalışmanın en dikkat çekici bulgusu, %97.39 seviyesindeki Specificity (Özgüllük) değeridir. Kvasir-SEG veri setinde arka plan piksellerinin polip piksellerine göre çok daha fazla olması (Sınıf Dengesizliği), modelleri genellikle "her yeri siyah tahmin etmeye" veya "aşırı yanlış alarm üretmeye" iter. Ancak eğitimde tercih edilen Dice Loss fonksiyonu, bu dengesizliği başarıyla yönetmiş ve modelin sağlıklı dokuyu %97 oranında doğru ayırt etmesini sağlamıştır. Bu, klinik kullanımda doktorun gereksiz yere uyarılmasını önlemek adına kritik bir avantajdır.
- İstatistiksel Dağılım Analizi (Şekil 2):** Şekil 2'deki Box Plot ve Histogram analizleri, modelin performans dağılımının sağa çarpık (left-skewed) olduğunu, yani test görüntülerinin büyük çoğunluğunda yüksek skorlar elde edildiğini göstermektedir. Medyan Dice skorunun (0.8689), ortalama Dice skorundan (0.7770) yüksek olması; modelin genel başarısının çok yüksek olduğunu, ancak sayıca az olan bazı "zorlu vakaların" (outliers) genel ortalamayı aşağı çektiğini istatistiksel olarak doğrulamaktadır.

5.2. Görsel Hata Analizi (Şekil 3)

Şekil 3'teki nitel sonuçlar incelendiğinde, modelin başarısını etkileyen temel faktörler şunlardır:

- Başarılı Durumlar:** Polip sınırlarının belirgin olduğu ve boyutun yeterli büyülükte olduğu görüntülerde, modelin tahmin maskesi ile uzman maskesi (Ground Truth) neredeyse birebir örtüşmektedir.
- Başarısız Durumlar:** Segmentasyon hatalarının yoğunlaştığı durumlar; (1) Çok küçük (milimetrik) polipler, (2) Düşük kontrastlı (bağırsak duvarı ile aynı renkteki) düz lezyonlar ve (3) Endoskopı ışığının yarattığı şiddetli yansımaların (specular reflection) olduğu bölgelerdir.

5.3. Kullanılan Yöntemlerin Değerlendirilmesi

Geliştirilen yaklaşımın güçlü ve zayıf yönleri, deneysel sonuçlar ışığında aşağıda özetlenmiştir:

Avantajlar	Dezavantajlar ve Kısıtlar
1. Yüksek Özgüllük (Specificity): Dice Loss kullanımını sayesinde yanlış pozitif oranı minimize edilmiş, sağlıklı doku başarıyla korunmuştur.	1. Küçük Nesne Problemi: U-Net mimarisindeki havuzlama (pooling) işlemleri, çok küçük poliplerin uzamsal bilgisinin kaybolmasına ve tespit edilememesine neden olabilmektedir.
2. Eğitim Kararlılığı: Standart U-Net'e eklenen Batch Normalization katmanları, gradyan akışını iyileştirmek modelin daha hızlı ve kararlı öğrenmesini sağlamıştır.	2. Işık Yansımalarına Duyarlılık: Model, bazı durumlarda parlak ışık yansımalarını yanlışlıkla polip dokusu olarak algılayabilmektedir.
3. Genelleştirme Yeteneği: Stratejik olarak yerleştirilen Dropout katmanları ve veri ön işleme (CLAHE) adımları, modelin ezberlemesini önleyerek görmediği verilerde de başarılı olmasını sağlamıştır.	3. Sınır Belirsizliği: Düşük kontrastlı geçiş bölgelerinde modelin ürettiği maske sınırları, uzman çizimine göre daha pürüzlü olabilmektedir.

5.4. Sonuç

Sonuç olarak; bu projede geliştirilen derin öğrenme tabanlı segmentasyon sistemi, yüksek doğruluk oranı ve düşük yanlış alarm seviyesi ile endoskopik işlemlerde doktorlara "ikinci bir göz" olarak yardımcı olma potansiyeline sahiptir. Gelecek çalışmalarda, küçük poliplerin tespiti için dikkat mekanizmalı (Attention U-Net) modellerin kullanılması ve veri setinin sentetik verilerle (Data Augmentation) zenginleştirilmesi önerilmektedir.

6. KAYNAKLAR

- [1] Jha, D., Smedsrud, P. H., Riegler, M. A., et al. (2020). *Kvasir-SEG: A segmented polyp dataset*. In Proceedings of the 11th ACM Multimedia Systems Conference. [Veri Kaynağı]: Kaggle Platformu (Official Dataset by Debesh Jha). [Erişim Adresi]: <https://www.kaggle.com/datasets/debeshjha1/kvasirseg>
- [2] Ronneberger, O., Fischer, P., & Brox, T. (2015). *U-Net: Convolutional networks for biomedical image segmentation*. In MICCAI. Springer, Cham. [Erişim Adresi]: <https://arxiv.org/abs/1505.04597>
- [3] Milletari, F., Navab, N., & Ahmadi, S. A. (2016). *V-net: Fully convolutional neural networks for volumetric medical image segmentation*. In 2016 Fourth International Conference on 3D Vision (3DV). IEEE. [Erişim Adresi]: <https://arxiv.org/abs/1606.04797>
- [4] Kingma, D. P., & Ba, J. (2014). *Adam: A method for stochastic optimization*. arXiv preprint arXiv:1412.6980. [Erişim Adresi]: <https://arxiv.org/abs/1412.6980>
- [5] Taha, A. A., & Hanbury, A. (2015). *Metrics for evaluating 3D medical image segmentation: analysis, selection, and tool*. BMC Medical Imaging, 15(1), 29. [Erişim Adresi]: <https://bmcmedimaging.biomedcentral.com/articles/10.1186/s12880-015-0068-x>
- [6] Albumentations Team. (2020). *Albumentations: Fast and flexible image augmentations*. [Erişim Adresi]: <https://albumentations.ai/>